

Conception d'un système intelligent pour le diagnostic automatique d'un nouveau diabète

Elhadji Abdoulaye Diankha

Université du Québec en Outaouais

Introduction & contexte


- Les systèmes de santé intelligents transforment les données médicales en connaissances exploitables.
- Le diabète est une maladie chronique causée par une production ou une utilisation inefficace de l'insuline.
- Deux types : Type 1 (insuffisance d'insuline) et Type 2 (résistance à l'insuline).

Description du dataset


- Variables : NUMPA, Genre, AGE, Urea, Cr, HbA1c, Chol, TG, HDL, LDL, VLDL, BMI,, CLASS
- Genre (M/F), CLASS (N, Y, P)
- Nombre d'observations : 1000
- Problème de classification

Analyse exploratoire


Distribution de l'âge



HbA1c vs CLASS






BMI vs CLASS



Prétraitement des données

- Nettoyage des valeurs aberrantes
- Encodage des variables catégorielles
- Normalisation / standardisation
- Gestion du déséquilibre (sur-échantillonnage)

[illegible]

Phase d'entraînement et de validation

- 60% de données attester aux données d'entraînement
- 40% attribué aux données test

Pour la validation:

- 20% de donnée attribuer aux données de test
- les 20% restant aux données de validation

Ojectif :

- Cette validation sert à valider notre model sur des données qu'ils n'ont jamais vue afin de s'assurer sur ses performances a pourvoir faire de l'apprentissage sur des données futures .

phase de modélisation

- Algorithmes d'apprentissage supervisé utilisés :
 - - Régression Logistique
 - - Forêt Aléatoire (Random Forest)
 - - Perceptron multicouche (MLP)
 - - Machine à vecteurs de support (SVM)

Sélection des caractéristiques et cross-validation

Méthodes utilisées :

- - RFE (Recursive Feature Elimination)
- Objectif : réduire la dimensionnalité tout en conservant la performance

cross-validation :

- - GridSearchCV pour trouver la meilleure combinaison d'hyperparamètres pour un modèle d'apprentissage automatique avec des splits de 5.

Résultats principaux

- Modèle Random Forest :
- - Accuracy : 98.07%
- - Précision : 98%
- - Rappel : 98%
- - F1-score : 98%
- - Log loss : 0.03

Comparaison des modèles

- Modèle | Accuracy | Précision | Rappel | F1-score
- -----|-----|-----|-----|-----
- Régression Logistique | 92.5% | 91% | 90% | 90%
- Random Forest | 98.07% | 98% | 98% | 98%
- MLP Classifier | 95% | 94% | 93% | 93%
- SVM | 94% | 93% | 92% | 92%

Conclusion & perspectives

- Random Forest est le modèle le plus performant.
- Perspectives :
 - - Intégration dans une application clinique
 - - Collecte de données plus variées
 - - Optimisation des hyperparamètres